INSA Rouen Normandie

Département Génie Mathématique

Cours

Théorie Spectrale des Graphes

Décomposition en valeurs singulières

Article portant sur le chapitre 1 de *Data-Driven Science and Engineering* (S. L. Brunton et J. N. Kutz)

Auteur :
Hippolyte Perraud

Année académique :
2026/2027

Septembre–Octobre 2026

Rouen, France

Table des matières

Résumé 2

1 Introduction 2

2 Définition de la SVD 2

3 Propriétés mathématiques 3

4 Approximation de rang faible 4

5 Pseudo-inverse, moindres carrés et régression 5

6 Analyse en composantes principales (PCA) 6

7 Exemple des *eigenfaces* 6

8 Troncature et alignement 7

9 SVD randomisée 8

10 Décompositions tensorielles 9

11 Conclusion 9

Résumé

Ce document résume le chapitre 1, consacré à la décomposition en valeurs singulières (SVD), de l'ouvrage *Data-Driven Science and Engineering* de S. L. Brunton et J. N. Kutz [1]. Il rappelle la définition de la SVD et ses propriétés (corrélations, géométrie, invariance unitaire), puis ses applications : approximation de rang faible (théorème d'Eckart–Young), pseudo-inverse et régression, analyse en composantes principales (PCA) et *eigenfaces*. Il aborde ensuite le choix de la troncature, l'alignement des données, la SVD randomisée et les décompositions tensorielles. Les notations du chapitre sont conservées partout ; une dernière section regroupe, séparément, des compléments hors chapitre.

1 Introduction

Selon [1, § 1], la SVD (*Singular Value Decomposition*) est l'une des factorisations matricielles les plus importantes de l'ère du calcul. Elle est numériquement stable et son existence est garantie pour toute matrice, contrairement à la décomposition en valeurs propres. Elle permet d'obtenir des approximations de rang faible, de calculer des pseudo-inverses de matrices non carrées pour résoudre $Ax = b$, et constitue l'algorithme sous-jacent de la PCA.

Les systèmes complexes produisent des données naturellement rangées en grandes matrices : série temporelle dont chaque colonne contient les mesures à un instant donné, pixels d'une image, images d'un film remises en forme de vecteurs colonnes. Ces données sont typiquement de *rang faible* : quelques motifs dominants expliquent les données de grande dimension, et la SVD les extrait de façon robuste et efficace. Elle généralise en ce sens la transformée de Fourier rapide (FFT) : la FFT fournit une base générique, la SVD une base *adaptée aux données*, découverte sans connaissance d'expert. Elle fonde d'autres méthodes du livre : classification, décomposition en modes dynamiques (DMD) et décomposition orthogonale aux valeurs propres (POD).

2 Définition de la SVD

2.1 SVD complète et SVD économique

On analyse un jeu de données $X = \begin{bmatrix} x_1 & x_2 & \cdots & x_m \end{bmatrix} \in \mathbb{C}^{n\times m}$, dont les colonnes $x_k \in \mathbb{C}^n$ (les *snapshots*) sont des mesures issues d'expériences ou de simulations : images vectorisées, état d'un système physique évoluant dans le temps, etc. Souvent $n \gg m$ (matrice « haute et mince »), par opposition aux matrices « courtes et larges » ($n \ll m$). La SVD existe pour toute matrice complexe $X \in \mathbb{C}^{n\times m}$:

$$X = U\Sigma V^*, \tag{1}$$

où $U \in \mathbb{C}^{n\times n}$ et $V \in \mathbb{C}^{m\times m}$ sont *unitaires* ($UU^* = U^*U = I$) et $\Sigma \in \mathbb{R}^{n\times m}$ est diagonale à coefficients réels positifs ou nuls, rangés par ordre décroissant ; * désigne la transposée conjuguée. Les colonnes de U (resp. V) sont les *vecteurs singuliers gauches* (resp. *droits*) et les éléments diagonaux de Σ les *valeurs singulières*. Le rang de X est le nombre de valeurs singulières non nulles.

Lorsque $n \geq m$, on a $\Sigma = \begin{bmatrix} \hat{\Sigma} \\ 0 \end{bmatrix}$ avec $\hat{\Sigma} \in \mathbb{R}^{m \times m}$, d'où la *SVD économique* :

$$X = U\Sigma V^* = \begin{bmatrix} \hat{U} & \hat{U}_\perp \end{bmatrix} \begin{bmatrix} \hat{\Sigma} \\ 0 \end{bmatrix} V^* = \hat{U}\hat{\Sigma}V^*. \tag{2}$$

Les colonnes de $\hat{U}_\perp$ engendrent un espace complémentaire et orthogonal à celui de $\hat{U}$ et n'interviennent pas dans la reconstruction de X.

2.2 Calcul, historique et place de la SVD

Les implémentations sont matures : `svd` en Matlab et en R, `numpy.linalg.svd` en Python, `SingularValueDecomposition` en Mathematica, avec une option « économique » plus efficace pour les matrices non carrées. La plupart reposent sur LAPACK, dont la routine s'appelle `DGESVD`. Le chapitre cite les travaux fondateurs de Beltrami et Jordan (1873), Sylvester (1889), Schmidt (1907) et Weyl (1912), puis les travaux numériques de Golub. La SVD est à la base de la PCA (statistiques), de la transformée de Karhunen–Loève, des fonctions orthogonales empiriques (climat), de la POD (mécanique des fluides) et de l'analyse canonique des corrélations ; ces méthodes ne diffèrent souvent que par la collecte et le prétraitement des données.

3 Propriétés mathématiques

3.1 Corrélations dominantes et méthode des snapshots

En injectant la SVD économique dans les matrices de corrélation XX^* (produits scalaires des lignes) et X^*X (produits scalaires des colonnes), on obtient

$$XX^* = U \begin{bmatrix} \hat{\Sigma}^2 & 0 \\ 0 & 0 \end{bmatrix} U^*, \qquad X^*X = V\hat{\Sigma}^2 V^*. \tag{3}$$

Les colonnes de U sont donc les vecteurs propres de XX^*, celles de V ceux de X^*X, et chaque valeur singulière non nulle est la racine carrée positive d'une valeur propre commune à ces deux matrices. Si $X = X^*$, ses valeurs singulières sont les valeurs absolues de ses valeurs propres. Les colonnes de U sont hiérarchisées selon la corrélation qu'elles capturent dans les colonnes de X (et V de même pour les lignes).

Lorsque n est très grand, XX^* est impraticable (un million de composantes donne mille milliards de coefficients). En 1987, Sirovich a observé qu'on peut diagonaliser seulement X^*X, beaucoup plus petite : on obtient V et $\hat{\Sigma}$, on conserve la partie non nulle $\tilde{\Sigma}$ et les colonnes correspondantes $\tilde{V}$, puis on reconstruit les r premières colonnes de U par

$$\tilde{U} = X\tilde{V}\tilde{\Sigma}^{-1}. \tag{4}$$

C'est la *méthode des snapshots*.

3.2 Interprétation géométrique

Les colonnes de U forment une base orthonormée de l'espace des colonnes de X, celles de V de son espace des lignes ; si les colonnes de X sont des mesures spatiales au cours

du temps, U encode des motifs spatiaux et V des motifs temporels. Comme U et V sont unitaires, résoudre un système qui les fait intervenir se réduit à multiplier par la transposée conjuguée ($\mathcal{O}(n^2)$), contre $\mathcal{O}(n^3)$ pour une inversion générique. Géométriquement, X transforme la sphère unité $S^{n-1} \triangleq \{x \mid \|x\|_2 = 1\}$ en un ellipsoïde dont les demi-axes sont les $\sigma_k u_k$ (figure 1). Comme l'application est linéaire, savoir comment la sphère est transformée détermine l'image de tous les autres vecteurs.

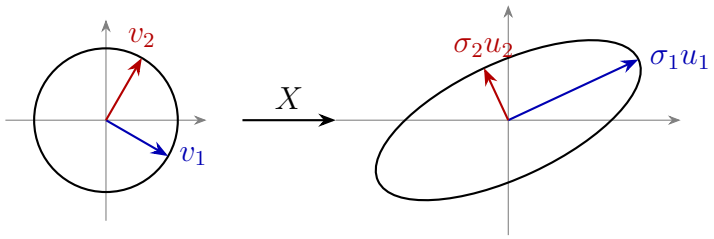


FIGURE 1 – Illustration schématique (cas 2×2) de l'image de la sphère unité par X.

Le chapitre l'illustre en dimension 3 avec $X = R_z R_y R_x \operatorname{diag}(\sigma_1, \sigma_2, \sigma_3)$, où R_x, R_y, R_z sont des rotations d'angles $\pi/15$, $-\pi/9$, $-\pi/20$ et $(\sigma_1, \sigma_2, \sigma_3) = (3, 1, 0{,}5)$: le produit $R_z R_y R_x$ est U et V est l'identité. Si une valeur singulière est nulle, l'ellipsoïde s'aplatit sur un sous-espace de dimension inférieure.

3.3 Invariance aux transformations unitaires

Multiplier X à gauche ou à droite par une matrice unitaire ne modifie que U ou V. Notons $U_X \Sigma_X V_X^*$ la SVD de X et $U_Y \Sigma_Y V_Y^*$ celle de Y.

- *À gauche,* $Y = CX$: $Y^*Y = X^*C^*CX = X^*X$, donc $V_Y = V_X$, $\Sigma_Y = \Sigma_X$ et, par la méthode des snapshots, $U_Y = Y V_X \Sigma_X^{-1} = C U_X$.
- *À droite,* $Y = XP^*$: $Y^*Y = P V_X \Sigma_X^2 V_X^* P^*$, donc $V_Y = P V_X$, $\Sigma_Y = \Sigma_X$ et $U_Y = Y P V_X \Sigma_X^{-1} = U_X$.

La transformée de Fourier discrète F étant unitaire, la SVD de $\hat{X} = FX$ a les mêmes valeurs singulières que celle de X, avec des modes transformés : $\hat{U} = FU$. Géométriquement, les transformations unitaires font tourner les vecteurs sans changer leurs produits scalaires ni les structures de corrélation.

4 Approximation de rang faible

La propriété la plus utile de la SVD est de fournir une *hiérarchie* d'approximations optimales de rang faible : une approximation de rang r s'obtient en conservant les r plus grandes valeurs singulières et les vecteurs associés. Schmidt a généralisé la SVD aux espaces de fonctions et établi ce résultat d'approximation, redécouvert par Eckart et Young.

Théorème 1 (Eckart–Young)**.** *L'approximation optimale de rang r de X, au sens des moindres carrés, est la troncature de rang r de la SVD, notée $\tilde{X}$:*

$$\underset{\substack{\tilde{X} \\ \operatorname{rang}(\tilde{X}) = r}}{\arg\min} \|X - \tilde{X}\|_F = \tilde{U} \tilde{\Sigma} \tilde{V}^*. \tag{5}$$

Ici $\tilde{U}$ et $\tilde{V}$ sont les r premières colonnes de U et V, $\tilde{\Sigma}$ est le bloc $r \times r$ en tête de Σ et $\|\cdot\|_F$ la norme de Frobenius. Comme Σ est diagonale, l'approximation est une somme de r matrices de rang 1 (*sommation dyadique*) :

$$\tilde{X} = \sum_{k=1}^{r} \sigma_k u_k v_k^* = \sigma_1 u_1 v_1^* + \cdots + \sigma_r u_r v_r^*. \tag{6}$$

Pour un rang r donné, aucune approximation n'est meilleure, au sens ℓ^2, que $\tilde{X}$; la base $\tilde{U}$ fournit un changement de coordonnées vers un espace de motifs de petite dimension. Si r est inférieur au rang de X, on a seulement $X \approx \tilde{U}\tilde{\Sigma}\tilde{V}^*$; si l'on garde toutes les valeurs singulières non nulles, l'égalité est exacte (le choix de r est discuté en section 8).

Exemple : compression d'image. Une image en niveaux de gris est une matrice $X \in \mathbb{R}^{n\times m}$ (n et m pixels dans les directions verticale et horizontale). Pour l'image de 2000×1500 pixels du chapitre, il suffit de stocker les r premières colonnes de U et V et les r premières valeurs singulières, soit $r(n + m + 1)$ valeurs au lieu de nm : 2,33 % du stockage pour $r = 20$ et 11,67 % pour $r = 100$. Dès $r = 100$, l'image reconstruite est assez fidèle et les valeurs singulières retenues représentent près de 80 % de la variance de l'image, car le spectre décroît très vite.

5 Pseudo-inverse, moindres carrés et régression

Soit le système $Ax = b$, avec $A \in \mathbb{C}^{n\times m}$. Si A est carrée inversible, la solution est unique ; sinon il peut y avoir une, aucune ou une infinité de solutions. Le système *sous-déterminé* ($n \ll m$) en admet en général une infinité et l'on cherche celle de norme $\|x\|_2$ minimale ; le système *sur-déterminé* ($n \gg m$) n'en admet que si $b \in \mathrm{col}(A)$ et l'on cherche sinon celle qui minimise $\|Ax - b\|_2^2$ (moindres carrés). Les quatre sous-espaces fondamentaux de $A = \tilde{U}\tilde{\Sigma}\tilde{V}^*$ (rang r incluant toutes les valeurs singulières non nulles) sont $\mathrm{col}(A) = \mathrm{col}(\tilde{U})$, son complément orthogonal $\ker(A^*)$ (colonnes de $\hat{U}_\perp$), $\mathrm{row}(A) = \mathrm{col}(A^*)$ (colonnes de $\tilde{V}$) et $\ker(A)$, avec $\mathrm{col}(A) \oplus \ker(A^*) = \mathbb{R}^n$ et $\mathrm{col}(A^*) \oplus \ker(A) = \mathbb{R}^m$.

En « inversant » tour à tour $\tilde{U}$, $\tilde{\Sigma}$ et $\tilde{V}^*$, on obtient le *pseudo-inverse de Moore–Penrose*, qui fournit les solutions de norme minimale et des moindres carrés :

$$A^\dagger \triangleq \tilde{V}\tilde{\Sigma}^{-1}\tilde{U}^*, \qquad \tilde{x} = A^\dagger b = \tilde{V}\tilde{\Sigma}^{-1}\tilde{U}^* b. \tag{7}$$

Pour A de rang colonne plein, c'est un inverse à gauche : $A^\dagger A = I_{m\times m}$. On a $A\tilde{x} = \tilde{U}\tilde{U}^* b$, projection de b sur $\mathrm{col}(\tilde{U})$: $\tilde{x}$ n'est solution exacte que si $b \in \mathrm{col}(A)$. Une fois la SVD calculée, $A^\dagger$ est peu coûteux : inverser $\tilde{U}$ et $\tilde{V}$ revient à les transposer ($\mathcal{O}(n^2)$) et $\tilde{\Sigma}$ diagonale coûte $\mathcal{O}(n)$, contre $\mathcal{O}(n^3)$ pour une matrice dense.

Régressions. Dans la régression à une variable du chapitre, des données bruitées sont obtenues en ajoutant un bruit gaussien à la droite $b = 3a$; avec $A = a$ colonne, on a $\tilde{\Sigma} = \|a\|_2$, $\tilde{V} = 1$, $\tilde{U} = a/\|a\|_2$ et la pente au sens des moindres carrés est $x = a^* b/\|a\|_2^2$. Le chapitre traite ensuite deux régressions multilinéaires : la chaleur dégagée par 13 mélanges de ciment à quatre ingrédients ($A \in \mathbb{R}^{13\times 4}$), et les prix de 506 logements à Boston en fonction de 13 attributs, matrice à laquelle on ajoute une colonne de 1 pour tenir compte d'un décalage constant. Les valeurs extrêmes élevées sont mal capturées par un ajustement linéaire.

Mise en garde. Avec une base tronquée, $\tilde{U}^*\tilde{U} = I_{r\times r}$ mais $\tilde{U}\tilde{U}^* \neq I_{n\times n}$: supposer le contraire est l'une des mauvaises utilisations les plus courantes de la SVD, dont les auteurs reconnaissent avoir eux-mêmes été victimes.

6 Analyse en composantes principales (PCA)

La PCA, développée par Pearson (1901) puis indépendamment par Hotelling dans les années 1930, fournit un système de coordonnées hiérarchisé, piloté par les données. Elle *prétraite* les données (soustraction de la moyenne, variance ramenée à l'unité) avant la SVD ; les composantes principales (PC) sont non corrélées et de corrélation maximale avec les mesures. Dans cette section, le chapitre adopte la convention de la PCA : chaque expérience est une ligne de $X \in \mathbb{R}^{n\times m}$. Avec $\bar{x}_j = \frac{1}{n}\sum_{i=1}^{n} X_{ij}$, $\bar{X} = \begin{bmatrix}1 & \cdots & 1\end{bmatrix}^T \bar{x}$ et $B = X - \bar{X}$, la covariance est $C = \frac{1}{n-1}B^*B$, et la première composante principale est

$$u_1 = \underset{\|u_1\|=1}{\arg\max}\, u_1^* B^* B u_1, \tag{8}$$

vecteur propre de B^*B pour la plus grande valeur propre, donc vecteur singulier de B associé à la plus grande valeur singulière (droit avec la convention en lignes ; gauche dans les exemples ci-dessous, où les mesures sont en colonnes). On obtient toutes les PC en diagonalisant C ($CV = VD$, toujours possible car C est hermitienne). Matlab propose `pca`, mais le chapitre préfère en général `svd` avec les prétraitements ci-dessus.

Exemple gaussien. On génère 10 000 vecteurs d'une loi normale 2D centrée réduite, mis à l'échelle par (2; 0,5), tournés de $\pi/3$ et translatés en $x_C = \begin{bmatrix}2 & 1\end{bmatrix}^T$. Les valeurs singulières normalisées valent 1,974 et 0,503 (pour des écarts-types de 2 et 0,5), et U est proche de la matrice de rotation $R_{\pi/3}$, au signe d'une colonne près :

$$R_{\pi/3} = \begin{bmatrix} 0{,}5 & -0{,}8660 \\ 0{,}8660 & 0{,}5 \end{bmatrix}, \qquad U = \begin{bmatrix} -0{,}4998 & -0{,}8662 \\ -0{,}8662 & 0{,}4998 \end{bmatrix}. \tag{9}$$

Cancer de l'ovaire. Le jeu de données intégré à Matlab porte sur 216 patientes (121 atteintes, 95 non atteintes), chacune décrite par l'expression de 4000 gènes. Ces données, très corrélées, ont une variance concentrée dans les premiers modes, et dans l'espace des trois premiers modes les patientes atteintes se regroupent à l'écart des autres : ce regroupement par catégorie est un élément fondateur de l'apprentissage automatique.

7 Exemple des *eigenfaces*

Étudié par Sirovich et Kirby (1987), puis appliqué à la reconnaissance faciale par Turk et Pentland (1991), ce problème applique la PCA à une bibliothèque d'images de visages. Le chapitre utilise l'*Extended Yale Face Database B* : images recadrées et alignées de 38 individus, dans 9 poses et 64 éclairages, de $192 \times 168 = 32\,256$ pixels chacune, vectorisées. Les 36 premières personnes servent à l'apprentissage et deux sont réservées au test. On soustrait le visage moyen, on empile les vecteurs en colonnes de X et la SVD de X donne les *eigenfaces* : les colonnes de U, qui peuvent être remises en forme d'images.

Une image de test absente de l'apprentissage est approchée par $\tilde{x}_{\text{test}} = \tilde{U}\tilde{U}^{*}x_{\text{test}}$ (appliquée à l'image centrée, le visage moyen étant rajouté). L'approximation est médiocre pour $r \leq 200$ et devient passable pour $r > 400$; le sous-espace engendré par les 1600 *eigenfaces* est assez grand pour approcher aussi l'image d'un chien ou d'un cappuccino. Les coordonnées $\tilde{\mathbf{x}} = \tilde{U}^{*}x$ forment un « espace des *eigenfaces* » : certaines composantes capturent les traits communs à tous les visages, d'autres distinguent les individus, d'autres l'angle d'éclairage. En projetant les 64 images de deux individus sur les 5e et 6e composantes, elles apparaissent bien séparées : c'est la base de la classification d'images du chapitre 5 du livre.

8 Troncature et alignement

8.1 Seuil dur optimal

Choisir le rang de troncature est l'une des décisions les plus importantes et débattues. On conserve souvent assez de valeurs singulières pour capturer 90 % ou 99 % de l'énergie (technique grossière mais courante), ou l'on repère un « coude » dans le spectre. La troncature est un *seuillage dur* : on garde les valeurs singulières supérieures à un seuil τ. Gavish et Donoho donnent le seuil optimal lorsque $X = X_{\text{true}} + \gamma X_{\text{noise}}$, avec X_{true} de rang faible et X_{noise} à coefficients gaussiens i.i.d. centrés réduits (γ est noté `sigma` dans le code du chapitre). Trois cas se présentent (tableau 1).

Cas	Seuil optimal τ
$X \in \mathbb{R}^{n\times n}$ carrée, γ connu	$\tau = (4/\sqrt{3})\,\sqrt{n}\,\gamma$
$X \in \mathbb{R}^{n\times m}$ rectangulaire ($m \leq n$), γ connu	$\tau = \lambda(\beta)\,\sqrt{n}\,\gamma$
$X \in \mathbb{R}^{n\times m}$ rectangulaire, γ inconnu	$\tau = \omega(\beta)\,\sigma_{\text{med}}$

Table 1 – Seuils durs optimaux pour la troncature des valeurs singulières.

Avec $\beta = m/n$ (ou n/m si $n \ll m$),

$$\lambda(\beta) = \left(2(\beta+1) + \frac{8\beta}{(\beta+1) + (\beta^2 + 14\beta + 1)^{1/2}}\right)^{1/2}, \tag{10}$$

qui se réduit à $4/\sqrt{3}$ pour $\beta = 1$. Si γ est inconnu (cas le plus fréquent), on utilise la valeur singulière médiane σ_{med} et $\omega(\beta) = \lambda(\beta)/\mu_\beta$, où μ_β est la solution, à approcher numériquement, de

$$\int_{(1-\sqrt{\beta})^2}^{\mu_\beta} \frac{\sqrt{\big((1+\sqrt{\beta})^2 - t\big)\big(t - (1-\sqrt{\beta})^2\big)}}{2\pi t}\,dt = \frac{1}{2}. \tag{11}$$

Sur un problème-jouet de rang 2 bruité ($\gamma = 1$, $n = 600$), le seuil $\tau \approx 56{,}6$ isole exactement les deux valeurs singulières du signal et filtre le bruit bien mieux qu'une troncature à 90 % de l'énergie. Pour les *eigenfaces* ($\beta = 3/4$, bruit inconnu), il sépare les colonnes de U qui portent de fortes caractéristiques faciales de celles qui sont surtout du bruit.

8.2 Importance de l'alignement des données

La SVD repose sur une séparation des variables entre colonnes et lignes ; quand cette hypothèse tombe (ondes progressives, données mal alignées), le rang est artificiellement gonflé. Dans l'exemple du chapitre, un carré blanc de uns sur fond de zéros ($n = 1000$), parfaitement aligné avec les axes, a une seule valeur singulière non nulle ; dès qu'on le fait tourner (de 10°, puis de 0° à 44° par pas de 4°), de nombreuses valeurs singulières non nulles apparaissent. La raison est que la SVD est fondamentalement *géométrique* : elle dépend du système de coordonnées et n'est invariante que par transformations unitaires, qui préservent le produit scalaire. C'est à la fois une force (interprétations géométriques, unités et dimensions significatives) et une faiblesse : le rang explose lorsque des objets sont translatés, tournés ou mis à l'échelle. L'exemple des *eigenfaces* repose ainsi sur des images soigneusement recadrées et alignées, et la SVD, méthode de choix pour les données d'EDP, échoue par exemple sur les ondes progressives. Disposer de décompositions généralisées applicables à des données présentant des symétries reste un défi ouvert.

9 SVD randomisée

Si X a une structure de rang faible, des algorithmes fondés sur l'échantillonnage aléatoire en donnent une décomposition précise pour une fraction du coût des méthodes déterministes. Leur intérêt grandit avec les données massives (vidéos 4K et 8K, internet des objets), dont le rang intrinsèque n'augmente guère avec la dimension de mesure. Pour $X \in \mathbb{R}^{n\times m}$ haute et mince et un rang cible $r < m$, l'algorithme de Halko, Martinsson et Tropp, qui demande deux passages sur X, procède ainsi :

1. on échantillonne l'espace des colonnes par une matrice aléatoire $P \in \mathbb{R}^{m\times r}$: $Z = XP$; une projection aléatoire élimine très improbablement des composantes importantes, donc Z approche l'espace des colonnes de X. On en tire une base orthonormée par décomposition QR, $Z = QR$;
2. on projette X dans ce sous-espace, $Y = Q^*X$ (soit $X \approx QY$), et l'on calcule la SVD de Y : $Y = U_Y \Sigma V^*$; Σ et V sont ceux de X (invariance unitaire) ;
3. on reconstruit les vecteurs singuliers gauches : $U = QU_Y$.

Passer de r à $r+p$ colonnes dans P (*sur-échantillonnage*, avec $p \approx 5$ ou 10) améliore nettement les résultats. Si le spectre décroît lentement, on applique q *itérations de puissance*, $X^{(q)} = (XX^*)^q X = U\Sigma^{2q+1}V^*$, dont le spectre décroît plus vite, au prix de q passages supplémentaires sur X.

Les bornes d'erreur sont explicites en fonction de r, p et q. Le meilleur sous-espace Q de rang r vérifie $\|X - QY\|_2 \geq \sigma_{r+1}(X)$, et pour l'algorithme randomisé

$$\mathbb{E}\big(\|X - QY\|_2\big) \leq \left[1 + \sqrt{\frac{r}{p-1}} + \frac{e\sqrt{r+p}}{p}\sqrt{m-r}\right]^{\frac{1}{2q+1}} \sigma_{r+1}(X). \tag{12}$$

Pour P, on utilise le plus souvent des matrices gaussiennes (très peu susceptibles d'éliminer de l'information, mais coûteuses à générer, stocker et appliquer), ou des alternatives : matrices de Rademacher (± 1), projections structurées (coût $\mathcal{O}(nm \log r)$), creuses, ou simple sélection de colonnes de X, option la plus rapide mais risquée si la structure est localisée. Le chapitre applique l'algorithme à une image haute résolution avec $r = 400$, $q = 1$ et $p = 5$, en comparant l'erreur relative en norme 2 à celle de la SVD déterministe.

10 Décompositions tensorielles

La SVD oblige à aplatir en un seul vecteur des données de natures différentes (température, pression, concentration…), ce qui n'a généralement pas de sens. On généralise donc les matrices en tableaux à N voies, ou *tenseurs*. Pour un tenseur de données $\mathcal{M}$ à N voies, le modèle *CANDECOMP/PARAFAC* (CP) à R composantes s'écrit

$$\mathcal{M} = \sum_{r=1}^{R} \lambda_r \, a_r^{(1)} \circ \cdots \circ a_r^{(N)}, \tag{13}$$

où $\circ$ est le produit extérieur, $a_r^{(n)}$ la r-ième colonne de la *matrice de facteurs* $A^{(n)}$ de taille $I_n \times R$, et les λ_r les *poids* (facteurs normalisés en colonnes). Dans le cas à 3 voies, avec deux modes d'état et un mode temporel : $\mathcal{M} = \sum_{r=1}^{R} \lambda_r \, A_r \circ B_r \circ C_r$.

Le chapitre décompose, avec la *N-way toolbox* de Matlab, un tenseur $\mathcal{A} \in \mathbb{R}^{121 \times 101 \times 315}$ (environ 10^6 points) issu de

$$F(x, y, t) = \exp\!\left(-x^2 - 0{,}5y^2\right) \cos(2t) + \operatorname{sech}(x) \tanh(x) \exp\!\left(-0{,}2y^2\right) \sin(t). \tag{14}$$

Un modèle CP à deux facteurs retrouve exactement les fonctions qui l'ont engendré : des gaussiennes en y, une gaussienne et $\operatorname{sech}(x)\tanh(x)$ en x, et les dynamiques $\cos(2t)$ et $\sin(t)$. La décomposition CP passe toutefois mal à l'échelle quand le nombre de voies augmente ; des techniques randomisées, ou des contraintes sur la forme des facteurs, aident à la rendre tractable et interprétable.

11 Conclusion

La SVD est un outil d'une grande généralité : elle existe pour toute matrice, est numériquement stable, fournit la meilleure approximation de rang donné (Eckart–Young), généralise le pseudo-inverse et les moindres carrés, et sous-tend la PCA. Ses limites sont concrètes : le choix du rang de troncature est délicat (le seuil de Gavish et Donoho apporte une réponse sous hypothèse de bruit gaussien) et sa sensibilité à l'alignement impose un prétraitement rigoureux. Les versions randomisées et tensorielles montrent qu'elle reste un sujet actif et qu'elle est le point de départ de la DMD et de la POD, abordées dans la suite de l'ouvrage.

Références

[1] S. L. Brunton et J. N. Kutz, *Data-Driven Science and Engineering : Machine Learning, Dynamical Systems, and Control*, Cambridge University Press, chapitre 1 : « Singular Value Decomposition (SVD) », pp. 3–46.